

Facultad de Ciencias Exactas, Ingeniería y Agrimensura

Tecnicatura Universitaria en Inteligencia Artificial



PROCESAMIENTO DE IMÁGENES

IA 4.4

Informe N°2

Año: 2025

Grupo: 1

Integrantes:

- Calabozo, Nicolas - C-7551/5
- Perez, Sebastián - P-5334/1
- Lapolla, Martín Facundo - L-3372/3

Fecha de presentación: 01/12/2025

Docentes:

- Ing. Gonzalo Sad
- Ing. Juan Manuel Calle
- Ing. Joaquín Allione

Introducción

El presente informe corresponde a la resolución del Trabajo Práctico N°2, cuyo propósito es aplicar conceptos de segmentación y detección de objetos mediante el desarrollo de dos problemas enfocados en la extracción automática de información en imágenes.

En el Problema 1, se aborda el desafío de clasificar y cuantificar objetos sobre un fondo de intensidad no uniforme. El objetivo es elaborar un algoritmo capaz de segmentar automáticamente monedas y dados, permitiendo no solo clasificar los tipos de monedas presentes, sino también interpretar y sumar los valores numéricos de las caras de los dados detectados.

Por otro lado, el Problema 2 se plantea como una aplicación de reconocimiento vehicular sobre un conjunto de imágenes de automóviles. En este caso, se combinan técnicas de localización y procesamiento morfológico para detectar la región de la placa patente y, posteriormente, lograr la segmentación individual de los caracteres que la componen.


Ambos desarrollos se implementaron utilizando la biblioteca OpenCV, junto con NumPy y Matplotlib, asegurando la visualización de los resultados en cada etapa del procesamiento.

Problema 1 - Segmentación y Clasificación de Monedas y Dados

Para dar solución al problema de detección y clasificación de monedas y dados en una imagen con fondo de intensidad no uniforme, se diseñó un algoritmo secuencial estructurado en seis etapas de procesamiento:


Etapa 1: Preprocesamiento

Dada la naturaleza del fondo, se optó por trabajar en el dominio de los bordes. Inicialmente, se convirtió la imagen a escala de grises y se aplicó un filtrado para suavizar el ruido.



Posteriormente, se utilizó el algoritmo de detección de bordes Canny, el cual es robusto frente a los cambios graduales de iluminación del fondo, permitiendo resaltar únicamente las transiciones de alta frecuencia correspondientes a los límites entre los objetos y el fondo.

1. Canny




Etapa 2: Morfología - Tratamiento de imagen para segmentar contornos


La salida del detector Canny suele presentar discontinuidades o líneas finas que no forman regiones cerradas. Para solucionar esto, se aplicaron operaciones morfológicas (dilatación, rellenado y erosión) con el fin de conectar los trazos y consolidar los bordes. Esto nos da un primer acercamiento para que, al buscar contornos, se obtengan figuras cerradas que representen lo más fielmente posible la geometría de los objetos presentes.

Comenzando por la dilatación, se tuvo que utilizar un kernel lo suficientemente grande de 21x21, seleccionado de manera experimental, para que los bordes detectados por Canny engloben la totalidad de la geometría de los objetos. Una vez dilatada la imagen y asegurado el cierre de los contornos, se aplicó una función para el rellenado de agujeros, obteniendo así una máscara binaria sólida representativa de cada objeto.

2. Dilate (21x21)




3. Relleno




Posteriormente, se realizó una erosión con el mismo tamaño de kernel (21x21) utilizado en la dilatación. El propósito de esta operación inversa es contrarrestar el aumento de área provocado por la dilatación inicial, ajustando así los bordes de las máscaras lo más cerca posible al tamaño real de los objetos representados.

4. Erosion (21x21)



5. Filtro de Mediana (13x13)



Finalmente, se utilizó un filtro de mediana con un kernel de 13x13. Esta etapa final tiene una doble función: eliminar pequeñas zonas de ruido (sal y pimienta) generados por las operaciones morfológicas y, simultáneamente, suavizar los bordes de las máscaras resultantes para facilitar la posterior clasificación por forma.

Etapa 3: Clasificación Detección de Dados y Monedas


Utilizando la máscara obtenida en la Etapa 2, encontramos los contornos de cada objeto en la imagen. Una vez obtenidos los contornos candidatos, se procedió a diferenciar entre "dados" y "monedas". Para ello se utilizó el Factor de Forma Inverso, definido mediante la relación entre el área y el perímetro del objeto. Este descriptor es invariante a la escala y rotación, permitiendo separar los objetos en dos grupos: aquellos con geometría cuadrada (dados) y aquellos con geometría circular (monedas).

ETAPA 3: Detección - 17 Monedas - 2 Dados - Factor de Forma: 15.5



La imagen obtenida por nuestro procesamiento hasta el momento presenta bordes, alrededor de los objetos, que no son regulares. Si bien la forma general es correcta, estas irregularidades impactan significativamente el cálculo del factor de forma inverso ya que aumentan artificialmente el perímetro de cada objeto observado. Nuestra máscara obtenida de la etapa dos, sin embargo, es lo suficientemente regular como para poder discriminar entre dados y monedas.

Para ello decidimos establecer un umbral a partir del cual podremos realizar esta clasificación binaria.



Un umbral de decisión posible puede ser el promedio entre el factor de forma máximo de las monedas y el mínimo de los dados.

Etapla 4: Normalización de Contornos de Monedas

Debido a la presencia de bordes irregulares en las monedas, el área calculada directamente del contorno puede tener variaciones. Como nuestro objetivo es discriminar el tipo de moneda por tamaño, en esta etapa se normalizan las monedas detectadas, ajustando su forma a una elipse de área mínima a partir de los contornos. Esto permite obtener una medida de radio y área más consistente a la hora de clasificar los tipos de moneda. Podemos visualizar el resultado de dicho ajuste en la siguiente imagen.

ETAPA 4 - Normalización - Elipses Ajustadas al Contorno Original




Etapa 5: Clasificación de Monedas por Área

Con los contornos normalizados, se realiza la clasificación del valor de la moneda. Dado que el tamaño físico de las monedas es el discriminante principal, se establecieron umbrales de área basados en el radio calculado, agrupando las detecciones en sus respectivas denominaciones según su tamaño relativo en la imagen.

ETAPA 5 - Clasificación por Tamaño (Area de la Elipse)



Para visualizar el criterio de corte, utilizamos el siguiente histograma



Podemos observar claramente en la distribución de área de las monedas, los criterios de corte para la clasificación. Tomamos un área máxima de 74000 píxeles cuadrados para clasificar las monedas de diez centavos, un área mínima de 94000 píxeles cuadrados para las monedas de cincuenta centavos y, por descarte, obtuvimos las monedas de un peso.

Etapla 6: Clasificación de Dados por Análisis de Componentes Internos

Finalmente, para determinar el valor de los dados, se analizaron los componentes internos de los contornos clasificados como cuadrados. Se utilizó nuevamente un criterio de forma para validar que los elementos internos correspondan a los puntos del dado y no a ruido o reflejos. Una vez validados los puntos mediante su circularidad, se procedió al conteo de los mismos para asignar la etiqueta numérica correspondiente a cada dado.

Extracción de ROI y Enmascaramiento

Para aislar el problema y evitar interferencias del entorno, se extrajo la Región de Interés correspondiente al bounding box del dado detectado. Sobre esta imagen se aplicó la máscara binaria generada en la Etapa 2. Esto permite apagar el fondo, asegurando que el análisis de intensidad se realice exclusivamente sobre la superficie del dado.

Segmentación de Candidatos

Se realizó una umbralización sobre la ROI para detectar las regiones oscuras que contrastan con la superficie clara del dado. En esta fase, el algoritmo detecta todos los componentes conexos oscuros, lo cual incluye tanto los puntos legítimos como no deseados, tales como sombras proyectadas por el dado sobre el fondo

Dado 21: ROI Original



Máscara



Filtrado por Factor de Forma

Para discriminar entre los puntos del dado y el ruido, se reutilizó el descriptor de Factor de Forma Inverso.

Dado que los puntos de los dados son circulares por diseño, podemos utilizar la misma técnica para contabilizar los puntos reales, eliminando así los elementos no deseados que no se conformen al factor de forma circular.

Se aplicó un filtro que valida únicamente aquellos contornos cuya circularidad se encuentra dentro de un rango de tolerancia elegido. Esta vez, el umbral se seleccionó de manera informada.

Umbralado + Filtro



Resultado: 5



Conteo y Asignación de Etiqueta

Finalmente, el algoritmo contabiliza la cantidad de componentes que superaron la etapa de filtrado. Este número entero se asigna directamente como la etiqueta de clase del objeto. En el ejemplo ilustrado, se validaron 5 componentes, clasificando la cara con un valor de '5'.

ETAPA 6 - Clasificación de Dados por Factor de Forma



En esta imagen podemos observar la correcta clasificación de ambas caras de los dados, con los contornos resaltados y los valores asociados a sus caras.


Problema 2: Detección y Segmentación de Patentes

El objetivo de este problema consiste en el desarrollo de un algoritmo capaz de detectar y segmentar automáticamente la placa patente en una serie de imágenes de autos y luego segmentar los caracteres.

Etapla 1: Preprocesamiento


Para optimizar el procesamiento y reducir la aparición de falsos positivos en áreas irrelevantes (como el cielo, árboles o parabrisas), definimos un recorte automático de la imagen (ROI). Descartamos el 25% superior, el 5% inferior y un 20% en los márgenes laterales, centrando el análisis exclusivamente en la zona donde tiende a ubicarse la patente. Luego de esto convertimos la región de interés a escala de grises y aplicamos una mejora de contraste local (CLAHE) para resaltar los caracteres incluso en condiciones de sombra. Posteriormente, suavizamos la imagen con un filtro Gaussiano.

Sobre la imagen preprocesada aplicamos Sobel vertical para detectar los bordes, debido a que los caracteres de la patente presentan una componente vertical que contrasta con el fondo de la chapa. El resultado se binarizó mediante Otsu.



Etapa 2: Operaciones Morfológicas

Para distinguir los caracteres de la patente de otros elementos como el suelo o parrillas, diseñamos una secuencia de operaciones morfológicas a llevar a cabo. Primero aplicamos una operación de apertura con un elemento estructural rectangular vertical (1x5), esto actuó como un filtro de tamaño y forma, eliminando el ruido granular pequeño (como la textura del piso) pero conservando los trazos verticales de los caracteres. A continuación, utilizamos una clausura con un kernel horizontal (13x3), esto permitió fusionar los caracteres individuales en un único objeto sólido sin conectar la patente con elementos superiores o inferiores como el paragolpes.



Etapa 3: Filtrado de Candidatos y Validación:

Análisis de contornos

A continuación se realiza un análisis de contorno para detectar efectivamente la patente. Para ello se extraen contornos y se analizan mediante 'minAreaRect'. Se conservan sólo aquellos con una relación de aspecto entre 2.0 y 4.5 y una inclinación menor a 45°. También se aplica un filtro de solidez (extent o rectangularidad).

Validación de Textura (Canny)

Finalmente, para asegurar que el candidato seleccionado fuera efectivamente una patente y no un bloque sólido (como una óptica o un espejo), implementamos una validación de textura basada en Canny. Analizamos la densidad de bordes en tres líneas de corte horizontales a distintas alturas del candidato. Una patente válida debe presentar una cantidad consistente de transiciones (cortes) en estas líneas debido a la alternancia de los caracteres y el fondo. Como resultado de esto el algoritmo logró aislar exitosamente la región de la patente en la totalidad de las 12 imágenes.

5. Detección



6. Recorte Final



Etapa 4: Segmentación de Caracteres

Una vez extraído el recorte de la patente, se procede a aislar los caracteres individuales. Para lograr la segmentación, implementamos una función que procesa el recorte de la patente basándonos en la premisa de que los caracteres son regiones oscuras (o claras, dependiendo de la patente) con una geometría y disposición espacial específica. Esta etapa se caracteriza por tener un flujo principal y un fallback en caso de no poder detectar la totalidad de los caracteres de la patente en el flujo principal.

Preprocesamiento del Recorte

A partir de la patente obtenida por la etapa anterior, inicialmente, descartamos un pequeño margen perimetral de la imagen recortada (10% superior/inferior y 2% lateral) para eliminar bordes o restos del marco de la patente. Luego, convertimos la imagen a escala de grises y aplicamos un filtro bilateral. A diferencia del suavizado Gaussiano utilizado previamente, el filtro bilateral nos permitió reducir el ruido de alta frecuencia (granulado) preservando los bordes filosos de los caracteres, lo cual es crítico para mantener su definición morfológica.

Patentes preprocesadas



Estrategia de Binarización

Dado que las condiciones de iluminación y defectos en la patente varían, se diseñaron dos flujos de procesamiento que compiten para obtener el mejor resultado.

1 - Flujo Principal: Umbralado Adaptativo

Dado que las patentes pueden presentar sombras parciales o reflejos, un umbral global fijo no resulta del todo eficiente. Implementamos un umbralado adaptativo Gaussiano, el cual calcula el umbral para cada píxel basándose en una ventana local ponderada. Esto nos permitió separar eficazmente los caracteres incluso en condiciones de iluminación no uniforme, generando una máscara binaria más robusta.


La selección de los parámetros para la umbralización se encontraron a partir de Trackbars, eligiendo los que proveen la mejor separación de los caracteres del fondo de la patente, en la mayor cantidad de patentes posibles.

Patente 1 - Binarizado con Trackbars



Si bien este umbralado es lo suficientemente bueno como para aislar los caracteres del fondo de nueve de las doce patentes, no es efectivo para segmentar correctamente la totalidad de las mismas.

Patente 2 y 10 - Filtrado adaptativo




Es por eso que optamos por implementar un flujo secundario que permita obtener una mejor separación en los casos donde el umbralado adaptativo falle.

2 - Flujo de Respaldo (Fallback): Otsu Modificado

La estrategia de binarización se basa en el algoritmo de Otsu, el cual calcula automáticamente un umbral global óptimo para separar el fondo del frente. Sin embargo, detectamos experimentalmente que el valor umbral de intensidad retornado por Otsu estándar no era suficiente para aislar correctamente los caracteres. Es por eso que implementamos un sistema de trackbars para poder encontrar un desplazamiento del umbral base que lograra la separación buscada. Llegamos a la conclusión que un desplazamiento de 30 unidades de intensidad de píxel sobre el umbral original es el que proporciona los mejores resultados para estos casos.

Patente 2 y 10 - Umbralado Otsu+30



Filtrado y Selección de Caracteres:

Sobre la imagen binarizada, como primer acercamiento, encontramos todos los componentes conectados. Para discernir cuáles correspondían a caracteres y cuáles a ruido, aplicamos un primer filtrado basado en restricciones geométricas. Primero en base a un área mínima se descartaron componentes menores a 20 píxeles, y aquellos con altura de 0 píxeles.


Después del filtrado geométrico, persistían elementos indeseados con formas similares a letras (como tornillos o marcas en la chapa). Para resolver esto, desarrollamos una función de agrupación basada en la consistencia estadística de las dimensiones de los caracteres. Calculamos la mediana de la altura y del área de todos los candidatos detectados. Conservamos únicamente aquellos contornos que se mantenían dentro de una tolerancia específica respecto a estas medianas (15% en altura y 60% en área), logrando así eliminar outliers por diferencias de tamaño sin depender de la alineación vertical, simplificando el modelo sin sacrificar detecciones.

Patente 1 y 2 - Máscaras finales



A partir de las componentes conectadas válidas, construimos las áreas de interés alrededor de cada caracter, con su bounding box asociado.

Patente 1 y 2 - Detección de caracteres



Etapas 5: Visualización de Resultados

Finalmente, unificamos los resultados obtenidos en una imagen que combina todas las etapas desde la detección de patente, de caracteres y segmentación de los mismos.



Conclusión

En el Problema 1, la principal dificultad fue la no uniformidad del fondo, lo que nos hizo descartar el uso de un umbralado global simple. Comprobamos que trabajar en el dominio de los bordes utilizando Canny seguido de una etapa morfológica robusta (dilatación y relleno de agujeros) fue la estrategia más eficaz que encontramos para obtener máscaras sólidas. Un punto importante de este desarrollo fue la validación práctica de los descriptores geométricos: el Factor de Forma Inverso demostró ser una herramienta discriminante muy buena para separar geometrías cuadradas (dados) de circulares (monedas) de manera invariante a la rotación, permitiendo posteriormente una clasificación basada puramente en áreas normalizadas y conteo de componentes internos.

Por otro lado, el Problema 2 presentó el mayor desafío técnico al enfrentarnos a imágenes del mundo real con iluminación variable, ruido y diferentes perspectivas. En la etapa de segmentación de patentes, la principal complejidad resultó ser el filtrado de todos los candidatos de patente posibles. Logramos, a partir de filtros geométricos de área, inclinación de la patente, rectangularidad y relación de aspecto, junto a un filtro de textura utilizando Canny, la detección de la totalidad de patentes.

El siguiente desafío fue en la segmentación de caracteres, a la hora de umbralizar, donde el uso de trackbars facilitó de gran manera la selección de los parámetros de umbralización. Notamos que nuestro flujo principal era capaz de detectar ocho de las doce patentes, lo que nos dio la idea de implementar una función nueva, que utilizara otro método de umbralización para captar las cuatro restantes. Logramos la detección de tres de esas cuatro patentes utilizando un umbral Otsu modificado, que permitió aislar correctamente el fondo de la patente de los caracteres en esos casos problemáticos.

En definitiva, este trabajo nos permitió integrar las etapas de segmentación con la extracción de características, evidenciando que una buena elección de descriptores geométricos y una buena umbralización simplifican drásticamente la lógica de clasificación posterior.